

07MIAR_04_B_2026-27_REDES NEURONALES Y DEEP LEARNING

Foro Evaluable: Estudio Factorial de la Regularización (L_1 , L_2 , None) y la Tasa de Aprendizaje (α) en TensorFlow Playground

Evaluación empírica en TensorFlow Playground: trazabilidad de pérdidas en interfaz web, medición de enlaces muertos k/34 e interacción entre contracción estocástica y capacidad representacional

AUTOR

Samuel Segundo Campozano López

FECHA DE ENTREGA

4 de octubre de 2026 (Límite: 18 de octubre de 2026)

REGISTRO OFICIAL EN FORO BLACKBOARD (NORMAS 6 Y 7)

Hilo publicado el 27/09/2026 a las 16:28 — Combinación factorial verificada sin colisión

1. Fundamentación Teórica y Mecánica de Desconexión en Playground

En el entrenamiento de perceptrones multicapa (MLP), el riesgo empírico se combina con términos de penalización funcional [1, 3]. En el entorno interactivo de TensorFlow Playground [2] y su motor subyacente (src/nn.ts) [4], la optimización se ejecuta mediante descenso de gradiente estocástico (SGD sin momento) sobre minilotes de tamaño $B = 10$:

$$w \leftarrow w - (\alpha / B) \sum \partial E / \partial w ; \qquad w_{\text{nuevo}} \leftarrow w - (\alpha \cdot \lambda) \cdot \Omega'(w)$$

donde $\Omega'(w) = \text{sgn}(w)$ en L_1 y $\Omega'(w) = w$ en L_2 . En nn.ts se implementa un umbral con congelación permanente para L_1 : si la actualización hace que el peso cruce el origen ($w \cdot w_{\text{nuevo}} < 0$), el peso se fija a 0 y el enlace se marca como muerto (link.isDead = true), omitiéndose en posteriores propagaciones [4].

Con 400 muestras de entrenamiento y $B = 10$, cada época consta de 40 pasos; en 500 épocas se ejecutan $T = 20.000$ actualizaciones por enlace. Si un peso carece de gradiente útil sostenido, la contracción acumulada potencial es $\Delta w \approx \alpha \lambda T$. Como los pesos inician en $U[-0.5, 0.5]$: a $\alpha = 0.003$ ($\lambda = 0.003$), $\alpha \lambda T = 0.18 < 0.50$ (la contracción potencial no domina sobre la dispersión inicial; se preserva la conectividad básica); a $\alpha = 0.03$, $\alpha \lambda T = 1.80 > 0.50$ (la contracción acumulada supera el rango inicial, permitiendo que las conexiones sin gradiente suficiente alcancen el cruce de cero dentro del presupuesto de T actualizaciones); y a $\alpha = 0.3$, con independencia del regularizador, el elevado paso de aprendizaje α induce inestabilidad de optimización y sobrepaso estocástico (overshooting) en el entorno del mínimo.

2. Protocolo Experimental y Rejilla 3x3 en Dataset Circle

Conforme a la **Norma 3**, se fija una red de 3 capas ocultas [4, 4, 2] (topología $2 \rightarrow 4 \rightarrow 4 \rightarrow 2 \rightarrow 1$), con **34 pesos entrenables** y 11 sesgos no regularizados. Entradas: coordenadas (X_1, X_2); Activación: Tanh; Ruido: 10%; Split: 80% train / 20% test (400/100 muestras, **Norma 2**); $\lambda = 0.003$. Se evalúan 3 semillas pseudoaleatorias controladas ($s \in \{0.42, 0.101, 0.2024\}$). Para garantizar reproducibilidad y auditoría estricta de la **Norma 1**, la aplicación web oficial (playground.tensorflow.org) fue ejecutada mediante Puppeteer en Chromium sin modificar el código de la plataforma. El entrenamiento se ejecuta controlando exactamente 500 épocas (500 pulsaciones secuenciales del botón #next-step-button tras cargar los hiperparámetros en la URL), extrayéndose las lecturas de los elementos #loss-train y #loss-test a 3 decimales, reportando la media muestral μ y la desviación estándar muestral σ ($n - 1$ grados de libertad). La esparsidad se midió inspeccionando la propiedad __data__ asociada por D3.js a cada trazado SVG (<path id^="link">) para acceder al atributo nativo link.isDead === true (ver volcado JSON en el repositorio público). En configuraciones saturadas se observan coincidencias entre semillas (e.g., train 0.035 en L_1 o $k = [22, 22, 22]$), compatibles con la resolución nativa de 3 decimales y convergencia hacia niveles equivalentes de esparsidad en la muestra evaluada.

TABLA 1. MEDICIONES DIRECTAS EN INTERFAZ DE TENSORFLOW PLAYGROUND — DATASET CIRCLE (RUIDO 10%, 500 ÉPOCAS, N=3 SEMILLAS)

Regularizador	Learning Rate (α)	Lecturas Train [s_1, s_2, s_3]	Train Loss ($\mu \pm \sigma$)	Lecturas Test [s_1, s_2, s_3]	Test Loss ($\mu \pm \sigma$)	Enlaces Muertos [s_1, s_2, s_3]	Esparsidad Media
None	0.003	[0.044, 0.028, 0.025]	0.0323 $\pm$ 0.0102	[0.102, 0.096, 0.103]	0.1003 $\pm$ 0.0038	[0, 0, 0] / 34	0 / 34 (0.0%)
None	0.03	[0.026, 0.024, 0.026]	0.0253 $\pm$ 0.0012	[0.095, 0.100, 0.104]	0.0997 $\pm$ 0.0045	[0, 0, 0] / 34	0 / 34 (0.0%)
None	0.3	[0.033, 0.036, 0.048]	0.0390 $\pm$ 0.0079	[0.097, 0.097, 0.155]	0.1163 $\pm$ 0.0335	[0, 0, 0] / 34	0 / 34 (0.0%)
L₁ ($\lambda=0.003$)	0.003	[0.041, 0.036, 0.035]	0.0373 $\pm$ 0.0032	[0.068, 0.079, 0.082]	0.0763 $\pm$ 0.0074	[3, 5, 9] / 34	5.7 / 34 (16.7%)
L ₁ ($\lambda=0.003$)	0.03	[0.035, 0.035, 0.035]	0.0350 $\pm$ 0.0000	[0.083, 0.084, 0.084]	0.0837 $\pm$ 0.0006	[20, 22, 22] / 34	21.3 / 34 (62.7%)
L ₁ ($\lambda=0.003$)	0.3	[0.083, 0.060, 0.076]	0.0730 $\pm$ 0.0118	[0.132, 0.111, 0.142]	0.1283 $\pm$ 0.0158	[22, 22, 22] / 34	22.0 / 34 (64.7%)
L ₂ ($\lambda=0.003$)	0.003	[0.046, 0.033, 0.031]	0.0367 $\pm$ 0.0081	[0.098, 0.087, 0.086]	0.0903 $\pm$ 0.0067	[0, 0, 0] / 34	0 / 34 (0.0%)
L₂ ($\lambda=0.003$)	0.03	[0.032, 0.032, 0.032]	0.0320 $\pm$ 0.0000	[0.084, 0.081, 0.081]	0.0820 $\pm$ 0.0017	[0, 0, 0] / 34	0 / 34 (0.0%)
L ₂ ($\lambda=0.003$)	0.3	[0.035, 0.040, 0.038]	0.0377 $\pm$ 0.0025	[0.115, 0.082, 0.107]	0.1013 $\pm$ 0.0172	[0, 0, 0] / 34	0 / 34 (0.0%)




Figura 1. Captura de ejecución en TensorFlow Playground (Circle, L_2 , $\alpha=0.03$, semilla 0.42, 500 épocas). Parámetros fijados en el panel DATA (split 80/20, ruido 10%, batch 10, red [4, 4, 2] con tanh) y superficie de separación concéntrica regular frente al ruido (test loss visible: 0.084, train loss: 0.032, 0/34 enlaces muertos).

3. Evaluación en Dataset Spiral y Límite de Capacidad Representacional

Se somete la misma arquitectura factorial al dataset **Spiral** (Norma 8), caracterizado por dos ramas helicoidales entrelazadas de 1.75 vueltas: TABLA 2. MEDICIONES DIRECTAS EN INTERFAZ DE TENSORFLOW PLAYGROUND — DATASET SPIRAL (RUIDO 10%, 500 ÉPOCAS, N=3 SEMILLAS)

Regularizador	Learning Rate (α)	Lecturas Train [s_1, s_2, s_3]	Train Loss ($\mu \pm \sigma$)	Lecturas Test [s_1, s_2, s_3]	Test Loss ($\mu \pm \sigma$)	Enlaces Muertos [s_1, s_2, s_3]	Comportamiento Estructural
None	0.003	[0.480, 0.478, 0.473]	0.4770 $\pm$ 0.0036	[0.453, 0.451, 0.445]	0.4497 $\pm$ 0.0042	[0, 0, 0] / 34	Estancado en meseta inicial.
None	0.03	[0.473, 0.298, 0.272]	0.3477 $\pm$ 0.1093	[0.445, 0.305, 0.310]	0.3533 $\pm$ 0.0794	[0, 0, 0] / 34	Bimodal: s_1 falla (0.445); s_2 y s_3 trazan corte oblicuo.
None	0.3	[0.326, 0.444, 0.410]	0.3933 $\pm$ 0.0607	[0.327, 0.423, 0.440]	0.3967 $\pm$ 0.0609	[0, 0, 0] / 34	s_1 desciende (0.327); s_2, s_3 inestables en meseta.
L_1 ($\lambda=0.003$)	0.003	[0.481, 0.480, 0.480]	0.4803 $\pm$ 0.0006	[0.457, 0.457, 0.456]	0.4567 $\pm$ 0.0006	[9, 16, 21] / 34	Pérdida cercana al límite trivial (≈ 0.46).
L_1 ($\lambda=0.003$)	0.03	[0.480, 0.480, 0.480]	0.4800 $\pm$ 0.0000	[0.461, 0.461, 0.462]	0.4613 $\pm$ 0.0006	[25, 28, 28] / 34	Poda severa (79.4%); red bloqueada en meseta.
L_1 ($\lambda=0.003$)	0.3	[0.479, 0.479, 0.479]	0.4790 $\pm$ 0.0000	[0.461, 0.461, 0.461]	0.4610 $\pm$ 0.0000	[30, 30, 30] / 34	88.2% enlaces muertos; salida fija.
L_2 ($\lambda=0.003$)	0.003	[0.481, 0.480, 0.479]	0.4800 $\pm$ 0.0010	[0.454, 0.454, 0.453]	0.4537 $\pm$ 0.0006	[0, 0, 0] / 34	Contracción homogénea; sin convergencia.
L_2 ($\lambda=0.003$)	0.03	[0.479, 0.478, 0.478]	0.4783 $\pm$ 0.0006	[0.455, 0.455, 0.456]	0.4553 $\pm$ 0.0006	[0, 0, 0] / 34	Estancado en meseta; sin resolución no lineal.
L_2 ($\lambda=0.003$)	0.3	[0.479, 0.479, 0.479]	0.4790 $\pm$ 0.0000	[0.458, 0.458, 0.458]	0.4580 $\pm$ 0.0000	[0, 0, 0] / 34	Pesos contraídos; sin resolución geométrica.




Figura 2. Captura de ejecución en TensorFlow Playground (Spiral, None, $\alpha=0.03$, semilla $s_1=0.42$, 500 épocas). Muestra la semilla s_1 , estancada casi sin separación efectiva entre clases (test loss: 0.445, train loss: 0.473). Con 34 pesos y coordenadas puras (X_1, X_2), la red carece de capacidad inductiva para resolver las espirales.

4. Discusión Crítica: Dinámica de Poda y Límites de Capacidad

1. Dinámica de Poda y Línea Base L_1 : Sin gradiente, un enlace muere si $|w_0| < \alpha T$; al inicializar en $w_0 \sim U[-0.5, 0.5]$, esto ocurre con probabilidad teórica base $\alpha T / 0.5 = 36\%$ (≈ 12 de 34 enlaces). Esta estimación sirve como línea base teórica ante ausencia de señal, no como cota estricta: en Spiral, donde la red queda atascada en meseta sin gradientes útiles sostenidos, se observan [9, 16, 21] enlaces muertos (media 45%), del mismo orden de magnitud ante $n = 3$; mientras que en Circle el gradiente activo protege la conectividad, reduciendo los muertos a solo 5,7 (16.7%). A $\alpha = 0.03$, la desconexión selectiva consolida una subred esparsa viable (21.3 muertos, test 0.0837 $\pm$ 0.0006). A $\alpha = 0.3$, la cifra de enlaces muertos se mantiene similar (22.0 vs. 21.3); por tanto, el número agregado de enlaces muertos no explica por sí solo la degradación del error a 0.1283, la cual es coherente, sobre todo, con el sobrepaso de gradiente (*overshooting*) propio de un paso agresivo con $B = 10$, patente también en None (0.1163) y L_2 (0.1013) [1, 3].

2. L_2 Continuo y Diagnóstico de la Brecha Train-Test: L_2 ($\alpha=0.03$, test 0.0820 $\pm$ 0.0017) empatía en generalización con L_1 conservador (0.0763 $\pm$ 0.0074), superando a None (0.0997 $\pm$ 0.0045) y preservando todos los enlaces (0/34 muertos). Resulta revelador analizar la *brecha de generalización* (test – train): en un modelo de 45 parámetros entrenables (34 pesos, 11 sesgos), la red sin regularizar sobreajusta el ruido ambiental del 10%, exhibiendo una brecha de 0.068–0.077 donde la pérdida de test supera entre 3 y 4 veces a la de train. Ambos regularizadores tienden a comprimir dicha brecha (L_1 : 0.039–0.055; L_2 : 0.050–0.064), resultado coherente con la mitigación de varianza: la brecha baja en 17 de 18 comparaciones por semilla (excepción: L_2 , $\alpha=0.3$, s_1). La esparsidad no estructurada de L_1 requiere librerías dispersas para aceleración real, y ante $n = 3$ la dispersión de L_2 es un indicador muestral [3].

3. Subajuste Estructural en Spiral: En Spiral, un clasificador constante en 0 rinde una pérdida cuadrática de 0.500. En este montaje experimental (entradas X_1, X_2 puras y red 4-4-2), las variantes con regularización (L_1, L_2) quedan atrapadas en valores próximos a dicho límite (0.453–0.461). A $\alpha = 0.003$, todas las arquitecturas (incluida None con 0.4497) permanecen en meseta. En cambio, sin regularizar, semillas con pasos más ágiles escapan a la simetría nula trazando planos de corte que reducen la pérdida (None $\alpha=0.03$ en s_2, s_3 con 0.305 y 0.310; y None $\alpha=0.3$ en s_1 con 0.327). Esto **sugiere** que en este montaje, la penalización de pesos agrava el subajuste cuando el modelo carece de la capacidad inductiva necesaria para resolver la geometría [3].

5. Conclusiones y Recomendaciones Normativas (Norma 9)

Basándose estrictamente en las mediciones empíricas registradas en TensorFlow Playground, se emiten las siguientes conclusiones y recomendaciones:

TABLA 3. MATRIZ NORMATIVA DE SELECCIÓN DE HIPERPARÁMETROS BASADA EN EVIDENCIA EXPERIMENTAL

Topología / Diagnóstico	Régimen Recomendado	Configuración Evaluada	Justificación Basada Estrictamente en Datos
Fronteras radiales convexas con ruido moderado (Circle)	L_2 continuo o L_1 conservador	L_2 ($\alpha=0.03, \lambda=0.003$) ó L_1 ($\alpha=0.003$)	Desempeño equivalente (test 0.076–0.082 frente a 0.100 en None). L_1 poda el 16.7% de enlaces; L_2 preserva conectividad completa sin desconexiones.
Poda estructural deliberada / Compresión de red (Circle)	L_1 con α moderado	L_1 ($\alpha=0.03, \lambda=0.003$)	Poda 21.3/34 enlaces (62.7% de esparsidad no estructurada) manteniendo test competitivo (0.0837 ± 0.0006) por gradiente fuerte en enlaces activos (requiere kernels dispersos para acelerar cómputo).
Tasas de aprendizaje agresivas ($\alpha = 0.3$)	Evitar $\alpha \geq 0.3$ en Circle	General a todos los regularizadores	El sobrepaso estocástico degrada la convergencia en todos los casos (None 0.1163, L_2 0.1013, L_1 0.1283). En L_1 , la pérdida no obedece a un salto sustancial de poda (22.0 vs. 21.3) sino a inestabilidad.
Variedades entrelazadas de alta curvatura (Spiral)	No regularizar en baja capacidad inductiva	None ($\alpha=0.03$) como base de optimización	En este montaje, regularizar parece reforzar el subajuste (pérdidas ≈ 0.45 – 0.46). Como hipótesis a contrastar en trabajo futuro, se requeriría ampliar arquitectura o proyectar a base armónica (sin/cos).

Hipótesis Metodológica sobre Dinámica de Poda: La tasa α modula la rapidez con que las conexiones con gradiente débil derivan hacia el cero en T pasos ($\Delta w \approx \alpha \lambda T$), mientras que teóricamente λ actuaría discriminando los enlaces con gradiente insuficiente ($|\partial E / \partial w| \leq \lambda$). En Circle, el recuento medio de enlaces muertos es similar entre $\alpha=0.03$ (21.3) y $\alpha=0.3$ (22.0).

6. Reproducibilidad y Código Abierto

Todas las evaluaciones fueron ejecutadas y capturadas sobre la aplicación web oficial de TensorFlow Playground (<https://playground.tensorflow.org>) en el motor Chromium mediante automatización en Puppeteer, registrando las lecturas directas del panel (#loss-train y #loss-test) e inspeccionando el estado interno de los enlaces (isDead y weight) mediante el enlace de datos de D3.js. El código ejecutor (run_playground.js), el registro bruto de las 54 ejecuciones (resultados_brutos.csv con enlaces muertos, marcas temporales y URLs directas), el volcado JSON (links_isDead_run.json) y las capturas íntegras se encuentran depositados en:

https://github.com/samuelbetzler/07MIAR_04_B_2026-27_Neural-Networks-and-Deep-Learning

Estado base verificable para la semilla 0.42:

<https://playground.tensorflow.org/#activation=tanh®ularization=L2&batchSize=10&dataset=circle&learningRate=0.03®ularizationRate=0.003&noise=10&networkShape=4,4,2&seed=0.42&percTrainData=80&x=true&y=true>

Referencias Bibliográficas

[1] Tibshirani, R. (1996). *Regression shrinkage and selection via the lasso*. Journal of the Royal Statistical Society: Series B (Methodological), 58(1), 267–288.

[2] Smilkov, D., Carter, S., Sculley, D., Viégas, F. B., & Wattenberg, M. (2017). *Direct-manipulation visualization of deep networks*. arXiv preprint arXiv:1708.03788 (presentado en ICML Workshop on Visualization for Deep Learning).

[3] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. Capítulo 7: Regularization for Deep Learning (pp. 224–270).

[4] TensorFlow Playground. (2016). *Repositorio oficial de código abierto*. Google Inc. Disponible en: <https://github.com/tensorflow/playground>. Regla de desconexión y cruce por cero implementada en src/nn.ts (commit bd89e3a, 8 de marzo de 2017). Consulta: 4 de octubre de 2026.