

07MIAR\_04\_B\_2026-27\_REDES NEURONALES Y DEEP LEARNING

# Foro Evaluable: Estudio Factorial de la Regularización ( $L_1$ , $L_2$ , None) y la Tasa de Aprendizaje ( $\alpha$ ) en TensorFlow Playground

*Evaluación empírica en TensorFlow Playground: trazabilidad de pérdidas en interfaz web, medición de enlaces muertos k/34 e interacción entre contracción estocástica y capacidad representacional*

AUTOR

Samuel Segundo Campozano López

FECHA DE ENTREGA

4 de octubre de 2026 (Límite: 18 de octubre de 2026)

REGISTRO OFICIAL EN FORO BLACKBOARD (NORMAS 6 Y 7)

Hilo publicado el 27/09/2026 a las 16:28 — Combinación factorial verificada sin colisión

1. Fundamentación Teórica y Mecánica de Desconexión en Playground

En el entrenamiento de perceptrones multicapa (MLP), el riesgo empírico se combina con términos de penalización funcional [1, 3]. En el entorno interactivo de TensorFlow Playground [2] y su motor subyacente (src/nn.ts) [4], la optimización se ejecuta mediante descenso de gradiente estocástico (SGD sin momento) sobre minilotes de tamaño  $B = 10$ :

$$w \leftarrow w - (\alpha / B) \sum \partial E / \partial w ; \quad w_{\text{nuevo}} \leftarrow w - (\alpha \cdot \lambda) \cdot \Omega'(w)$$

donde  $\Omega'(w) = \text{sgn}(w)$  en  $L_1$  y  $\Omega'(w) = w$  en  $L_2$ . En nn.ts se implementa un umbral con congelación permanente para  $L_1$ : si la actualización hace que el peso cruce el origen ( $w \cdot w_{\text{nuevo}} < 0$ ), el peso se fija a 0 y el enlace se marca como muerto (link.isDead = true), omitiéndose en posteriores propagaciones [4].

Con 400 muestras de entrenamiento y  $B = 10$ , cada época consta de 40 pasos; en 500 épocas se ejecutan  $T = 20.000$  actualizaciones por enlace. Si un peso carece de gradiente útil sostenido, la contracción acumulada potencial es  $\Delta w \approx \alpha \lambda T$ . Como los pesos inician en  $U[-0.5, 0.5]$ : a  $\alpha = 0.003$  ( $\lambda = 0.003$ ),  $\alpha \lambda T = 0.18 < 0.50$  (la contracción potencial no domina sobre la dispersión inicial; se preserva la conectividad básica); a  $\alpha = 0.03$ ,  $\alpha \lambda T = 1.80 > 0.50$  (la contracción acumulada supera el rango inicial, permitiendo que las conexiones sin gradiente suficiente alcancen el cruce de cero dentro del presupuesto de  $T$  actualizaciones); y a  $\alpha = 0.3$ , con independencia del regularizador, el elevado paso de aprendizaje  $\alpha$  induce inestabilidad de optimización y sobrepaso estocástico (overshooting) en el entorno del mínimo.

2. Protocolo Experimental y Rejilla 3x3 en Dataset Circle

Conforme a la **Norma 3**, se fija una red de 3 capas ocultas [4, 4, 2] (topología  $2 \rightarrow 4 \rightarrow 4 \rightarrow 2 \rightarrow 1$ ), con **34 pesos entrenables** y 11 sesgos no regularizados. Entradas: coordenadas ( $X_1, X_2$ ); Activación: Tanh; Ruido: 10%; Split: 80% train / 20% test (400/100 muestras, **Norma 2**);  $\lambda = 0.003$ . Se evalúan 3 semillas pseudoaleatorias controladas ( $s \in \{0.42, 0.101, 0.2024\}$ ). Para garantizar reproducibilidad y auditoría estricta de la **Norma 1**, la aplicación web oficial (playground.tensorflow.org) fue ejecutada mediante Puppeteer en Chromium sin modificar el código de la plataforma. El entrenamiento se ejecuta controlando exactamente 500 épocas (500 pulsaciones secuenciales del botón #next-step-button tras cargar los hiperparámetros en la URL), extrayéndose las lecturas de los elementos #loss-train y #loss-test a 3 decimales, reportando la media muestral  $\mu$  y la desviación estándar muestral  $\sigma$  ( $n - 1$  grados de libertad). La esparsidad se midió inspeccionando la propiedad \_\_data\_\_ asociada por D3.js a cada trazado SVG (<path id^="link">) para acceder al atributo nativo link.isDead === true (ver volcado JSON en el repositorio público). En configuraciones saturadas se observan coincidencias entre semillas (e.g., train 0.035 en  $L_1$  o  $k = [22, 22, 22]$ ), compatibles con la resolución nativa de 3 decimales y convergencia hacia niveles equivalentes de esparsidad en la muestra evaluada.

TABLA 1. MEDICIONES DIRECTAS EN INTERFAZ DE TENSORFLOW PLAYGROUND — DATASET CIRCLE (RUIDO 10%, 500 ÉPOCAS, N=3 SEMILLAS)

| Regularizador                                     | Learning Rate ( $\alpha$ ) | Lecturas Train [ $s_1, s_2, s_3$ ] | Train Loss ( $\mu \pm \sigma$ )       | Lecturas Test [ $s_1, s_2, s_3$ ] | Test Loss ( $\mu \pm \sigma$ )        | Enlaces Muertos [ $s_1, s_2, s_3$ ] | Esparsidad Media        |
|---------------------------------------------------|----------------------------|------------------------------------|---------------------------------------|-----------------------------------|---------------------------------------|-------------------------------------|-------------------------|
| None                                              | 0.003                      | [0.044, 0.028, 0.025]              | 0.0323 $\pm$ 0.0102                   | [0.102, 0.096, 0.103]             | 0.1003 $\pm$ 0.0038                   | [0, 0, 0] / 34                      | 0 / 34 (0.0%)           |
| None                                              | 0.03                       | [0.026, 0.024, 0.026]              | 0.0253 $\pm$ 0.0012                   | [0.095, 0.100, 0.104]             | 0.0997 $\pm$ 0.0045                   | [0, 0, 0] / 34                      | 0 / 34 (0.0%)           |
| None                                              | 0.3                        | [0.033, 0.036, 0.048]              | 0.0390 $\pm$ 0.0079                   | [0.097, 0.097, 0.155]             | 0.1163 $\pm$ 0.0335                   | [0, 0, 0] / 34                      | 0 / 34 (0.0%)           |
| <b>L<sub>1</sub> (<math>\lambda=0.003</math>)</b> | <b>0.003</b>               | <b>[0.041, 0.036, 0.035]</b>       | <b>0.0373 <math>\pm</math> 0.0032</b> | <b>[0.068, 0.079, 0.082]</b>      | <b>0.0763 <math>\pm</math> 0.0074</b> | <b>[3, 5, 9] / 34</b>               | <b>5.7 / 34 (16.7%)</b> |
| L <sub>1</sub> ( $\lambda=0.003$ )                | 0.03                       | [0.035, 0.035, 0.035]              | 0.0350 $\pm$ 0.0000                   | [0.083, 0.084, 0.084]             | 0.0837 $\pm$ 0.0006                   | [20, 22, 22] / 34                   | 21.3 / 34 (62.7%)       |
| L <sub>1</sub> ( $\lambda=0.003$ )                | 0.3                        | [0.083, 0.060, 0.076]              | 0.0730 $\pm$ 0.0118                   | [0.132, 0.111, 0.142]             | 0.1283 $\pm$ 0.0158                   | [22, 22, 22] / 34                   | 22.0 / 34 (64.7%)       |
| L <sub>2</sub> ( $\lambda=0.003$ )                | 0.003                      | [0.046, 0.033, 0.031]              | 0.0367 $\pm$ 0.0081                   | [0.098, 0.087, 0.086]             | 0.0903 $\pm$ 0.0067                   | [0, 0, 0] / 34                      | 0 / 34 (0.0%)           |
| <b>L<sub>2</sub> (<math>\lambda=0.003</math>)</b> | <b>0.03</b>                | <b>[0.032, 0.032, 0.032]</b>       | <b>0.0320 <math>\pm</math> 0.0000</b> | <b>[0.084, 0.081, 0.081]</b>      | <b>0.0820 <math>\pm</math> 0.0017</b> | <b>[0, 0, 0] / 34</b>               | <b>0 / 34 (0.0%)</b>    |
| L <sub>2</sub> ( $\lambda=0.003$ )                | 0.3                        | [0.035, 0.040, 0.038]              | 0.0377 $\pm$ 0.0025                   | [0.115, 0.082, 0.107]             | 0.1013 $\pm$ 0.0172                   | [0, 0, 0] / 34                      | 0 / 34 (0.0%)           |




Figura 1. Captura de ejecución en TensorFlow Playground (Circle,  $L_2$ ,  $\alpha=0.03$ , semilla 0.42, 500 épocas). Parámetros fijados en el panel DATA (split 80/20, ruido 10%, batch 10, red [4, 4, 2] con tanh) y superficie de separación concéntrica regular frente al ruido (test loss visible: 0.084, train loss: 0.032, 0/34 enlaces muertos).

3. Evaluación en Dataset Spiral y Límite de Capacidad Representacional

Se somete la misma arquitectura factorial al dataset **Spiral** (Norma 8), caracterizado por dos ramas helicoidales entrelazadas de 1.75 vueltas: TABLA 2. MEDICIONES DIRECTAS EN INTERFAZ DE TENSORFLOW PLAYGROUND — DATASET SPIRAL (RUIDO 10%, 500 ÉPOCAS, N=3 SEMILLAS)

| Regularizador             | Learning Rate ( $\alpha$ ) | Lecturas Train [ $s_1, s_2, s_3$ ] | Train Loss ( $\mu \pm \sigma$ ) | Lecturas Test [ $s_1, s_2, s_3$ ] | Test Loss ( $\mu \pm \sigma$ ) | Enlaces Muertos [ $s_1, s_2, s_3$ ] | Comportamiento Estructural                                        |
|---------------------------|----------------------------|------------------------------------|---------------------------------|-----------------------------------|--------------------------------|-------------------------------------|-------------------------------------------------------------------|
| None                      | 0.003                      | [0.480, 0.478, 0.473]              | 0.4770 $\pm$ 0.0036             | [0.453, 0.451, 0.445]             | 0.4497 $\pm$ 0.0042            | [0, 0, 0] / 34                      | Estancado en meseta inicial.                                      |
| None                      | 0.03                       | [0.473, 0.298, 0.272]              | 0.3477 $\pm$ 0.1093             | [0.445, 0.305, 0.310]             | 0.3533 $\pm$ 0.0794            | [0, 0, 0] / 34                      | Bimodal: $s_1$ falla (0.445); $s_2$ y $s_3$ trazan corte oblicuo. |
| None                      | 0.3                        | [0.326, 0.444, 0.410]              | 0.3933 $\pm$ 0.0607             | [0.327, 0.423, 0.440]             | 0.3967 $\pm$ 0.0609            | [0, 0, 0] / 34                      | $s_1$ desciende (0.327); $s_2, s_3$ inestables en meseta.         |
| $L_1$ ( $\lambda=0.003$ ) | 0.003                      | [0.481, 0.480, 0.480]              | 0.4803 $\pm$ 0.0006             | [0.457, 0.457, 0.456]             | 0.4567 $\pm$ 0.0006            | [9, 16, 21] / 34                    | Pérdida cercana al límite trivial ( $\approx 0.46$ ).             |
| $L_1$ ( $\lambda=0.003$ ) | 0.03                       | [0.480, 0.480, 0.480]              | 0.4800 $\pm$ 0.0000             | [0.461, 0.461, 0.462]             | 0.4613 $\pm$ 0.0006            | [25, 28, 28] / 34                   | Poda severa (79.4%); red bloqueada en meseta.                     |
| $L_1$ ( $\lambda=0.003$ ) | 0.3                        | [0.479, 0.479, 0.479]              | 0.4790 $\pm$ 0.0000             | [0.461, 0.461, 0.461]             | 0.4610 $\pm$ 0.0000            | [30, 30, 30] / 34                   | 88.2% enlaces muertos; salida fija.                               |
| $L_2$ ( $\lambda=0.003$ ) | 0.003                      | [0.481, 0.480, 0.479]              | 0.4800 $\pm$ 0.0010             | [0.454, 0.454, 0.453]             | 0.4537 $\pm$ 0.0006            | [0, 0, 0] / 34                      | Contracción homogénea; sin convergencia.                          |
| $L_2$ ( $\lambda=0.003$ ) | 0.03                       | [0.479, 0.478, 0.478]              | 0.4783 $\pm$ 0.0006             | [0.455, 0.455, 0.456]             | 0.4553 $\pm$ 0.0006            | [0, 0, 0] / 34                      | Estancado en meseta; sin resolución no lineal.                    |
| $L_2$ ( $\lambda=0.003$ ) | 0.3                        | [0.479, 0.479, 0.479]              | 0.4790 $\pm$ 0.0000             | [0.458, 0.458, 0.458]             | 0.4580 $\pm$ 0.0000            | [0, 0, 0] / 34                      | Pesos contraídos; sin resolución geométrica.                      |



Figura 2. Captura de ejecución en TensorFlow Playground (Spiral, None,  $\alpha=0.03$ , semilla  $s_1=0.42$ , 500 épocas). Muestra la semilla  $s_1$ , estancada casi sin separación efectiva entre clases (test loss: 0.445, train loss: 0.473). Con 34 pesos y coordenadas puras ( $X_1, X_2$ ), la red carece de capacidad inductiva para resolver las espirales.

4. Discusión Crítica: Dinámica de Poda y Límites de Capacidad

1. **Dinámica de Poda y Saturación en  $L_1$ :** Sin gradiente, un enlace muere si  $|w_0| < \alpha\lambda T$ ; al inicializar en  $w_0 \sim \mathcal{U}[-0.5, 0.5]$ , esto ocurre con probabilidad teórica base  $\alpha\lambda T / 0.5 = 36\%$  ( $\approx 12$  de 34 enlaces). Esta estimación sirve como línea base teórica ante ausencia de señal, no como una cota estricta: en Spiral, donde la red queda atascada en meseta sin gradientes útiles sostenidos, se observan [9, 16, 21] enlaces muertos (media 45%), del mismo orden de magnitud ante  $n = 3$ ; mientras que en Circle el gradiente activo protege la conectividad, reduciendo los muertos a solo 5.7 (16.7%). A  $\alpha = 0.03$ , la desconexión selectiva consolida una subred esparsa viable (21.3 muertos, test 0.0837  $\pm$  0.0006). A  $\alpha = 0.3$ , la cifra de enlaces muertos se mantiene similar (22.0 vs. 21.3); por tanto, el número agregado de enlaces muertos no explica por sí solo la degradación del error a 0.1283, la cual responde primordialmente al sobrepaso de gradiente (*overshooting*) propio de un paso agresivo con  $B = 10$ , patente también en None (0.1163) y  $L_2$  (0.1013) [1, 3].
2.  **$L_2$  como Regularizador Continuo vs.  $L_1$ :**  $L_2$  ( $\alpha=0.03$ , test 0.0820  $\pm$  0.0017) empatara en capacidad predictiva con  $L_1$  conservador (0.0763  $\pm$  0.0074), superando a None (0.0997  $\pm$  0.0045).  $L_2$  preserva la totalidad de los enlaces (0/34 muertos), atenuando la varianza de los pesos sin truncamiento. Debe precisarse que la esparsidad no estructurada de  $L_1$  requiere bibliotecas de cómputo disperso para traducirse en aceleración real en hardware, y que con  $n = 3$  la menor dispersión observada en  $L_2$  es un indicador muestral sujeto a variabilidad estocástica [3].
3. **Subajuste Estructural en Spiral:** En Spiral, un clasificador constante en 0 rinde una pérdida cuadrática teórica de 0.500. En este montaje experimental (entradas  $X_1, X_2$  puras y red 4-4-2), las variantes con regularización ( $L_1, L_2$ ) quedan atrapadas en valores próximos a dicho límite (0.453–0.461). A  $\alpha = 0.003$ , todas las arquitecturas (incluida None con 0.4497) permanecen en meseta. En cambio, sin regularizar, semillas con pasos más ágiles escapan a la simetría nula trazando planos de corte que reducen la pérdida (None  $\alpha=0.03$  en  $s_2, s_3$  con 0.305 y 0.310; y None  $\alpha=0.3$  en  $s_1$  con 0.327). Esto **sugiere** que en este montaje, la penalización de pesos agrava el subajuste cuando el modelo carece de la capacidad inductiva necesaria para resolver la geometría [3].

5. Conclusiones y Recomendaciones Normativas (Norma 9)

Basándose estrictamente en las mediciones empíricas registradas en TensorFlow Playground, se emiten las siguientes conclusiones y recomendaciones:

TABLA 3. MATRIZ NORMATIVA DE SELECCIÓN DE HIPERPARÁMETROS BASADA EN EVIDENCIA EXPERIMENTAL

| Topología / Diagnóstico                                  | Régimen Recomendado                        | Configuración Evaluada                                            | Justificación Basada Estrictamente en Datos                                                                                                                                                                         |
|----------------------------------------------------------|--------------------------------------------|-------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Fronteras radiales convexas con ruido moderado (Circle)  | $L_2$ continuo o $L_1$ conservador         | $L_2$ ( $\alpha=0.03, \lambda=0.003$ ) ó $L_1$ ( $\alpha=0.003$ ) | Desempeño equivalente (test 0.076–0.082 frente a 0.100 en None). $L_1$ poda el 16.7% de enlaces; $L_2$ preserva conectividad completa sin desconexiones.                                                            |
| Poda estructural deliberada / Compresión de red (Circle) | $L_1$ con $\alpha$ moderado                | $L_1$ ( $\alpha=0.03, \lambda=0.003$ )                            | Poda 21.3/34 enlaces (62.7% de esparsidad no estructurada) manteniendo test competitivo (0.0837 ± 0.0006) por gradiente fuerte en enlaces activos (requiere kernels dispersos para acelerar cómputo).               |
| Tasas de aprendizaje agresivas ( $\alpha = 0.3$ )        | Evitar $\alpha \geq 0.3$ en Circle         | General a todos los regularizadores                               | El sobrepaso estocástico degrada la convergencia en todos los casos (None 0.1163, $L_2$ 0.1013, $L_1$ 0.1283). En $L_1$ , la pérdida no obedece a un salto sustancial de poda (22.0 vs. 21.3) sino a inestabilidad. |
| Variedades entrelazadas de alta curvatura (Spiral)       | No regularizar en baja capacidad inductiva | None ( $\alpha=0.03$ ) como base de optimización                  | En este montaje, regularizar parece reforzar el subajuste (pérdidas $\approx 0.45$ –0.46). Como hipótesis a contrastar en trabajo futuro, se requeriría ampliar arquitectura o proyectar a base armónica (sin/cos). |

**Hipótesis Metodológica sobre Dinámica de Poda:** La tasa  $\alpha$  modula la rapidez con que las conexiones con gradiente débil derivan hacia el cero en  $T$  pasos ( $\Delta w \approx \alpha \lambda T$ ), mientras que teóricamente  $\lambda$  actuaría discriminando los enlaces con gradiente insuficiente ( $|\partial E / \partial w| \leq \lambda$ ). En Circle, el recuento medio de enlaces muertos es similar entre  $\alpha=0.03$  (21.3) y  $\alpha=0.3$  (22.0).

6. Reproducibilidad y Código Abierto

Todas las evaluaciones fueron ejecutadas y capturadas sobre la aplicación web oficial de TensorFlow Playground (<https://playground.tensorflow.org>) en el motor Chromium mediante automatización en Puppeteer, registrando las lecturas directas del panel (#loss-train y #loss-test) e inspeccionando el estado interno de los enlaces (isDead y weight) mediante el enlace de datos de D3.js. El código ejecutor (run\_playground.js), el registro bruto de las 54 ejecuciones (resultados\_brutos.csv con enlaces muertos, marcas temporales y URLs directas), el volcado JSON (links\_isDead\_run.json) y las capturas íntegras se encuentran depositados en:

[https://github.com/samuelbetzler/07MIAR\\_04\\_B\\_2026-27\\_Redes-Neuronales-y-Deep-Learning](https://github.com/samuelbetzler/07MIAR_04_B_2026-27_Redes-Neuronales-y-Deep-Learning)

Estado base verificable para la semilla 0.42:

<https://playground.tensorflow.org/#activation=tanh&regularization=L2&batchSize=10&dataset=circle&learningRate=0.03&regularizationRate=0.003&noise=10&networkShape=4,4,2&seed=0.42&percTrainData=80&x=true&y=true>

Referencias Bibliográficas

[1] Tibshirani, R. (1996). *Regression shrinkage and selection via the lasso*. Journal of the Royal Statistical Society: Series B (Methodological), 58(1), 267–288.

[2] Smilkov, D., Carter, S., Sculley, D., Viégas, F. B., & Wattenberg, M. (2017). *Direct-manipulation visualization of deep networks*. arXiv preprint arXiv:1708.03788 (presentado en ICML Workshop on Visualization for Deep Learning).

[3] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. Capítulo 7: Regularization for Deep Learning (pp. 224–270).

[4] TensorFlow Playground. (2016). *Repositorio oficial de código abierto*. Google Inc. Disponible en: <https://github.com/tensorflow/playground>. Regla de desconexión y cruce por cero implementada en src/nn.ts (commit bd89e3a, 8 de marzo de 2017). Consulta: 4 de octubre de 2026.